

MRI Tabanlı Beyin Tümörü Sınıflandırma Projesi Raporu

Giriş

Beyin tümörleri, sinir sisteminin en ciddi hastalıklarından biri olarak kabul edilir ve erken teşhis, tedavinin başarısı açısından hayati bir öneme sahiptir. Günümüzde **Manyetik Rezonans Görüntüleme (MRI)** teknolojisi, beyin dokularını detaylı biçimde görüntüleyebilmesi sayesinde tümör teşhisinde en yaygın kullanılan tıbbi görüntüleme yöntemidir. Bu proje, **derin öğrenme tabanlı bir görüntü sınıflandırma sistemi** geliştirerek MRI görüntülerinden beyin tümörlerinin varlığını otomatik olarak tespit etmeyi amaçlamaktadır.

MRI Teknolojisi

MRI, güçlü manyetik alanlar ve radyo frekans dalgaları kullanarak vücudun iç yapısının kesitsel görüntülerini oluşturur. Bu yöntem, X-ray veya CT gibi iyonize radyasyon içeren yöntemlere göre çok daha güvenlidir. Özellikle yumuşak dokuların (örneğin beyin, kas, sinir sistemi) görüntülenmesinde yüksek kontrast sağlar. MRI cihazları farklı sekanslar (T1, T2, FLAIR vb.) kullanarak doku tiplerine göre farklı kontrastlar üretir. Bu da tümörlerin konumunun ve yapısının net biçimde tespit edilmesini sağlar.

Veri Seti

Bu projede kullanılan veri seti, **Kaggle** platformunda yayımlanan [Brain Tumor MRI Dataset](#) adlı açık kaynaklı veri setidir. Veri seti, toplamda **7023 adet MRI görüntüsünden** oluşmakta olup dört sınıf içerir:

- **Glioma Tümörü**
- **Meningioma Tümörü**
- **Pituitary Tümörü**
- **No Tumor (Tümör Yok)**

Görüntüler genellikle 224x224 piksel boyutlarında normalize edilmiştir ve RGB formatındadır. Veri seti, eğitim ve test verileri olarak ikiye ayrılmıştır.

Kullanılan Teknolojiler ve Yöntemler

Bu projede, **derin öğrenme tabanlı Convolutional Neural Network (CNN)** mimarisi kullanılmıştır. CNN'ler, özellikle görsel verilerdeki uzamsal ilişkileri öğrenmede oldukça etkilidir. Model, temel olarak şu katmanlardan oluşur:

- **Conv2D Katmanları:** Görüntüdeki kenar, şekil ve doku gibi düşük seviyeli özellikleri çıkarır.
- **MaxPooling Katmanları:** Özellik haritalarını küçülterek ağı daha az hesaplama yapmasını sağlar ve önemli bilgiyi korur.
- **Dropout Katmanları:** Eğitim sürecinde bazı nöronların rastgele kapatılmasıyla aşırı öğrenmeyi (overfitting) önler.
- **Dense (Tam Bağlantılı) Katmanlar:** Özellikleri sınıflandırarak nihai tahmini üretir.

Modelin derinleştirilmiş versiyonlarında, **ResNet (Residual Network)** mimarisi kullanılabilir. ResNet, "skip connection" adı verilen özel bağlantılarla derin ağlarda oluşabilecek **gradyan kaybolması** sorununu çözer. Bu sayede model, çok daha derin yapılarla yüksek doğrulukta öğrenme yapabilir.


Modelin derin öğrenme mimarisi **TensorFlow ve Keras** kütüphaneleri kullanılarak oluşturulmuştur. Eğitim sırasında **Adam optimizasyon algoritması** ve **categorical crossentropy** kayıp fonksiyonu kullanılmıştır. Adam, adaptif öğrenme oranı sayesinde parametre güncellemelerini daha verimli yapar.

Eğitim süreci 10 epoch boyunca gerçekleştirilmiştir. Her epoch, modelin tüm eğitim verisini bir kez görmesi anlamına gelir. Her epoch sonunda doğruluk (accuracy) ve kayıp (loss) değerleri kaydedilmiştir.

Eğitim Sonuçları

Eğitim sürecinde modelin doğruluk oranı epoch sayısına bağlı olarak artış göstermiş, doğrulama setinde ortalama %96 başarı elde edilmiştir. Aşağıda eğitim sürecinde elde edilen **accuracy** ve **loss** değerlerinin epoch sayısına göre değişimini gösteren grafik yer alabilir.

Epoch Bazında Accuracy ve Loss Grafiği



Sağlık Sektöründe Kullanım Alanları

Bu tür derin öğrenme tabanlı görüntü sınıflandırma sistemleri, sağlık sektöründe büyük bir dönüşüm potansiyeline sahiptir. Özellikle hastanelerde:

- **Erken Teşhis:** Radyologların gözünden kaçabilecek küçük tümörlerin bile otomatik olarak tespit edilmesini sağlar.
- **Tanı Destek Sistemi:** Doktorlara ek bir karar destek aracı sunarak yanlış teşhis riskini azaltır.
- **Otomatik Tarama:** Yüzlerce MRI görüntüsünü saniyeler içinde analiz ederek öncelikli hastaları belirler.
- **Cerrahi Planlama:** Tümörün yerleşimi ve büyüklüğü hakkında hızlı bilgi sağlayarak operasyon sürecini kolaylaştırır.

Geliştirme Önerileri

Proje gelecekte şu şekilde geliştirilebilir:

- Daha büyük ve çeşitli veri setleri kullanılarak **modelin genelleme yeteneği** artırılabilir.
- **Transfer Learning** yöntemleri (örneğin ResNet, EfficientNet, InceptionV3) kullanılarak doğruluk oranı artırılabilir.
- **3D MRI verilerinin** kullanımıyla derin dokusal analizler yapılabilir.

- **Hasta geçmişi ve klinik verilerin** modele entegre edilmesiyle kişiselleştirilmiş tanı sistemleri geliştirilebilir.
- Model, bulut tabanlı olarak geliştirilip **hastane bilgi sistemleriyle entegre** hale getirilebilir.

Sonuç

Bu proje, yapay zekâ tabanlı görüntü sınıflandırma modellerinin tıp alanında ne kadar güçlü bir araç olabileceğini göstermektedir. MRI görüntülerinden beyin tümörlerinin otomatik olarak sınıflandırılması, hem doktorların iş yükünü azaltmakta hem de erken teşhisin önünü açmaktadır. Bu tür sistemlerin gelecekte hastanelerde yaygın biçimde kullanılması, insan hatasını azaltarak tıbbi teşhis süreçlerinde devrim yaratabilir.